

UNIVERSIDAD TORCUATO DI TELLA, ESCUELA DE NEGOCIOS



MASTER IN MANAGEMENT & ANALYTICS

Métodos Estadísticos Aplicados a los Negocios

Trabajo Práctico

Daga Agustín - 25A2153

Hansman Dana - 25Y3304

Variables

- **Order_ID**: identificador único para cada orden (pedido).
- **Distance_km**: distancia de entrega, en kilómetros.
- **Weather**: condiciones meteorológicas durante la entrega: Despejado, Lluvioso, Nevado, Niebla y Viento.
- **Traffic_Level**: condiciones de tráfico clasificadas en Bajo, Medio o Alto.
- **Time_of_day**: la hora a la que tuvo lugar la entrega, clasificada como Mañana, Tarde, Tarde/Noche o Noche.
- **Vehicle_Type**: tipo de vehículo utilizado para la entrega, incluyendo Bicicleta, Scooter y Auto.
- **Preparation Time_min**: el tiempo necesario para preparar el pedido, en minutos.
- **Courier_Experience_yrs**: experiencia del mensajero, en años.
- **Delivery Time_min**: tiempo total de entrega, en minutos.

A. Eliminen todos los casos para los que las variables Weather, Time_of_day y Traffic_Level tienen datos perdidos. ¿Con cuántas observaciones se quedan? También reporten una tabla con los principales estadísticos descriptivos (mínimo, media, mediana, máximo, desvío estándar y número de observaciones) para las variables numéricas. Comenten.

A continuación, se exponen los resultados que arrojaron los principales estadísticos descriptivos de la base de datos luego de eliminar los datos perdidos para las variables Weather, Time_of_day y Traffic_Level:

	Mínimo	Media	Mediana	Máximo	Desvío_Estándar	N
Distance_km	0.59	10.07	10.29	19.99	5.69	912
Preparation_Time_min	5.00	16.99	17.00	29.00	7.26	912
Courier_Experience_yrs	0.00	4.64	5.00	9.00	2.92	883
Delivery_Time_min	8.00	56.45	55.00	141.00	21.58	912

Realizado el filtro sobre las tres variables indicadas, es posible observar que todas ellas resultan en 912 observaciones mientras que la columna Courier_Experience_yrs, cuenta con 883 dado que presenta datos faltantes (N/A). Para evitar el uso de campos con valores nulos a lo largo de este trabajo y en el cálculo de las diferentes estimaciones, se eliminaron también los 29 casos donde la variable que indica los años de experiencia del mensajero tiene datos nulos. A partir de eso, se exponen los principales resultados para esa base de datos:

	Mínimo	Media	Mediana	Máximo	Desvío_Estándar	N
Distance_km	0.59	10.05	10.28	19.99	5.69	883
Preparation_Time_min	5.00	17.02	17.00	29.00	7.26	883
Courier_Experience_yrs	0.00	4.64	5.00	9.00	2.92	883
Delivery_Time_min	8.00	56.43	55.00	141.00	21.57	883

Es posible observar que, para la distancia medida en km, la media y la mediana arrojan resultados cercanos, lo cual sugiere una distribución considerablemente simétrica. Por otro lado, la dispersión de 5.69 resulta moderada.

Para el caso del tiempo de preparación del pedido, también presenta una distribución aproximadamente simétrica con una dispersión promedio de los tiempos de preparación cerca de los 7 minutos y medio respecto a la media de 17.02 minutos.

De los resultados para el análisis de los años de experiencia del mensajero es posible ver que existen personas novatas con 0 años de experiencia, mientras que también hay mensajeros más experimentados con hasta 9 años de experiencia. Del promedio, es posible concluir que hay una tendencia a que los repartidores tienen menos experiencia aunque existen casos en que se desvían hasta casi 3 años del promedio.

Por último, el tiempo de delivery es aquél que presenta mayor variabilidad respecto al promedio, con casi 22 minutos de dispersión. Aunque la media y la mediana también toman valores cercanos entre sí, del valor máximo y mínimo se puede inferir que existieron desvíos en algunas entregas con un tiempo de demora elevado.

B. Muchas veces, como en este caso, se trabaja con variables categóricas por lo que es necesario convertirlas a numéricas. En machine learning, se llama one-hot encoding (OHE) al proceso de convertir las variables categóricas en binarias creando una variable dummy por cada categoría que toma la variable original. Apliquen este proceso a cada una de las variables categóricas de la base de datos. ¿Cuántas dummies tuvieron que generar?

Para la resolución de este inciso, el primer paso fue identificar las variables categóricas que se encuentran en la base de datos sobre la cual estamos trabajando. En ese sentido, las seleccionadas fueron: Weather, Traffic_Level, Time_of_Day y Vehicle_Type. Para cada variable, se creó una dummy por cada categoría existente:

- Para Weather, fueron 5 dummies: Clear, Foggy, Rainy, Snowy o Windy tomando valor 1 en caso de que la categoría fuese la indicada, 0 caso contrario.
- Para Traffic_Level, fueron 3 dummies: High, Low o Medium tomando valor 1 en caso de que la categoría fuese la indicada, 0 caso contrario.
- Para Time_of_Day, fueron 4 dummies: Afternoon, Evening, Morning o Night tomando valor 1 en caso de que la categoría fuese la indicada, 0 caso contrario.
- Para Vehicle_Type, fueron 3 dummies: Bike, Car o Scooter tomando valor 1 en caso de que la categoría fuese la indicada, 0 caso contrario.

En total entonces, se generaron 15 dummies para cubrir todos los escenarios descritos. Dentro de cada variable, las dummies generadas, corresponden a categorías mutuamente excluyentes y colectivamente exhaustivas.

C. Estimen por MCO un modelo en el cual expliquen el tiempo de entrega en función de la distancia y las dummies de Weather. Expliquen por qué no se reporta el coeficiente de una de las categorías. Justifiquen. Interpreten cada uno de los coeficientes estimados comentando las implicancias de la significatividad estadística en cada caso.

Al estimar un modelo incluyendo variables categóricas como lo es el caso de Weather, el programa omite automáticamente una de las variables dummy a fines de evitar el problema de colinealidad perfecta, es decir, que exista información redundante (doble contabilidad).

En este caso, por la forma en que fue planteado el modelo, la categoría Windy fue omitida automáticamente, por lo que todos los coeficientes estimados deben interpretarse en comparación con la condición meteorológica Windy.

```

Coefficients: (1 not defined because of singularities)
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  25.58523    1.60424   15.949 < 2e-16 ***
Clear        -1.47593    1.53905   -0.959  0.33783
Foggy         5.41566    1.92311    2.816  0.00497 **
Rainy         3.02055    1.69445    1.783  0.07500 .
Snowy         8.50659    1.98652    4.282 2.06e-05 ***
Windy         NA         NA         NA     NA
Distance_km   2.93270    0.07728   37.951 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 13.01 on 877 degrees of freedom
Multiple R-squared:  0.638,    Adjusted R-squared:  0.6359
F-statistic: 309.1 on 5 and 877 DF,  p-value: < 2.2e-16

```

Dados los resultados expuestos, la interpretación de los coeficientes tendrá como categoría “base” a Windy y sus valores serán referencias diferenciales con respecto a la condición base.

El valor de 25.58 para el intercepto indica que el tiempo promedio de entrega cuando la condición es Windy y la distancia es 0 km es aproximadamente 25.6 minutos (es el valor de la variable y en la categoría base). Si bien no tiene una interpretación muy útil en la práctica, es importante mencionarlo.

Cuando el clima se encuentra en condiciones “normales” (Clear), el tiempo de entrega se reduce en 1.47 minutos respecto del tiempo bajo condiciones ventosas (Windy). Asimismo, esta variable no resulta estadísticamente significativa dado que su p-valor es mayor que cualquier nivel de significatividad usual. Por eso, es posible afirmar que la diferencia no es significativa y que el tiempo de entrega es equivalente en ambas condiciones climáticas.

Para el caso en que Weather sea Foggy, el tiempo de entrega aumenta en 5.41 minutos en comparación con el escenario donde la condición meteorológica sea Windy. Este aumento, a diferencia del caso anterior, sí resulta estadísticamente significativo al 1% y 5%.

En caso de que el clima fuese lluvioso (Rainy), el tiempo de entrega aumenta 3.02 minutos con respecto al tiempo en condiciones ventosas siendo una diferencia que no resulta estadísticamente significativa con un p-valor del 7.5%.

Para climas con nieve, se observa un aumento en el tiempo de entrega de 8.5 minutos respecto de la categoría base (ventoso) y, con un p-valor muy cercano a 0, es una diferencia estadísticamente significativa.

Por último, del análisis de los resultados que arroja la variable Distance_km, se observa que, por cada kilómetro adicional de distancia, el tiempo de entrega aumenta en 2.93 minutos en promedio. Este efecto resulta estadísticamente significativo con un p-valor que resulta casi igual a 0. Esto hace sentido desde la lógica donde se espera que la distancia influya directamente en el tiempo de entrega de un pedido.

Como comentario adicional y, en términos prácticos, encontramos más coherente utilizar como categoría base a la categoría “Clear” en lugar de “Windy” dado que resulta más interesante y útil comparar cómo varía el tiempo de entrega cuando las condiciones climáticas no son la “normal”. Se expone el resultado para ese caso:

```
Residuals:
    Min       1Q   Median       3Q      Max
-33.541  -7.861  -1.182   6.638  68.723

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  24.10930    0.98225   24.545 < 2e-16 ***
Foggy         6.89158    1.45839    4.725 2.67e-06 ***
Rainy         4.49648    1.14109    3.941 8.78e-05 ***
Snowy         9.98251    1.54276    6.471 1.62e-10 ***
Windy         1.47593    1.53905    0.959  0.338
Distance_km   2.93270    0.07728   37.951 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 13.01 on 877 degrees of freedom
Multiple R-squared:  0.638,    Adjusted R-squared:  0.6359
F-statistic: 309.1 on 5 and 877 DF,  p-value: < 2.2e-16
```

De manera similar a lo detallado anteriormente, ahora los coeficientes observados deberán ser interpretados como la variación en el tiempo de entrega para cada una de las condiciones climáticas, en comparación con el tiempo de entrega en condiciones normales (Clear). Dado que todos los coeficientes resultan positivos, es posible notar que el tiempo de entrega aumenta siempre que el clima empeore, sea por niebla, lluvia, nieve o viento.

A diferencia del caso anterior, casi todas las variables resultan estadísticamente significativas al 0.1%.

Asimismo, se observa que el intercepto disminuye respecto al análisis anterior lo cual es coherente con que el tiempo de entrega sea menor cuando el clima está despejado que cuando está ventoso. La distancia en kilómetros no varía dado que no depende de las condiciones climáticas.

D. Al modelo del punto anterior incorporen el tiempo de preparación del pedido. ¿Mejora el ajuste del modelo? Justifiquen

Los resultados muestran que la inclusión del tiempo de preparación del pedido mejora significativamente el ajuste del modelo. Se toma en cuenta el modelo donde se omite "Clear" para una mejor interpretación.

En particular, el R^2 ajustado, que penaliza la incorporación de variables adicionales, se incrementa de 0.6359 a 0.7367. Esto indica que el nuevo modelo explica una proporción mayor de la variabilidad del tiempo de entrega, ajustando por el número de predictores utilizados. Adicionalmente, para este nuevo modelo, todas las variables resultan estadísticamente significativas al 5%.

```

Residuals:
    Min       1Q   Median       3Q      Max
-23.646  -6.263  -1.015   4.191   67.404

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    7.48308    1.23244   6.072 1.88e-09 ***
Foggy          7.65677    1.24094   6.170 1.04e-09 ***
Rainy          4.72569    0.97048   4.869 1.33e-06 ***
Snowy          9.55517    1.31220   7.282 7.33e-13 ***
Windy          2.86325    1.31102   2.184  0.0292 *
Distance_km    2.96507    0.06574  45.103 < 2e-16 ***
Preparation_Time_min 0.94444    0.05147  18.348 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 11.07 on 876 degrees of freedom
Multiple R-squared:  0.7385,    Adjusted R-squared:  0.7367
F-statistic: 412.3 on 6 and 876 DF,  p-value: < 2.2e-16

```

Asimismo, el error estándar de los residuos disminuye de 13.01 a 11.07, lo que implica que las predicciones del modelo ampliado se encuentran, en promedio, más cerca de los valores observados.

El coeficiente asociado a la preparación del pedido en el nuevo modelo es positivo y altamente significativo (coeficiente = 0.9444, $p < 2e-16$), lo cual sugiere que, manteniendo constantes las demás variables del modelo, cada minuto adicional en la preparación del pedido incrementa el tiempo de entrega en aproximadamente 0.94 minutos.

E. ¿Por qué creen que cambió el coeficiente de la distancia cuando pasamos del modelo del punto (c) al (d)? Justifiquen. Apoyen su respuesta con un razonamiento claro y preciso.

Al comparar el modelo (c) con el modelo (d), observamos un cambio en el coeficiente asociado a la variable Distance_km. Este cambio puede explicarse por la incorporación de una variable relevante que había sido omitida en el modelo anterior: el tiempo de preparación del pedido (Preparation_Time_min). La omisión de esta variable en el modelo (c) probablemente generaba un sesgo por variables omitidas, ya que el tiempo de preparación está correlacionado tanto con la distancia como con el tiempo total de entrega.

En consecuencia, es posible que el coeficiente de Distance_km en el modelo (c) estuviera subestimando el verdadero impacto de la distancia sobre el tiempo de entrega, al estar absorbiendo parcialmente el efecto de la variable omitida. Al incluir Preparation_Time_min en el modelo (d), se logra aislar mejor el efecto propio de la distancia, lo que permite una estimación más precisa y confiable de su impacto real sobre la variable dependiente.

F. Sobre el modelo del punto anterior agreguen las dummies del nivel de tráfico y evalúen la hipótesis de que, manteniendo constantes las demás variables, el tráfico alto duplica el tiempo de retraso que cuando hay tráfico intermedio. Comenten.

Al incluir estas nuevas variables, tomando como categoría base la condición de tráfico bajo (Low), observamos una mejora leve en el ajuste general del modelo. El R^2 ajustado ascendió a 0.7789, superando los valores obtenidos en los modelos anteriores (0.7367 y 0.6359 en los modelos d y c, respectivamente), lo cual indica una mayor proporción de la variabilidad explicada por el modelo.

```
Residuals:
    Min       1Q   Median       3Q      Max
-20.478  -5.107  -1.219   3.327  64.365

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    2.45888    1.22181    2.012  0.0445 *
Foggy          7.97890    1.13871    7.007 4.87e-12 ***
Rainy          4.72432    0.89019    5.307 1.41e-07 ***
Snowy          9.92914    1.20453    8.243 6.11e-16 ***
Windy          1.87860    1.20373    1.561  0.1190
Distance_km     2.96141    0.06028   49.126 < 2e-16 ***
Preparation_Time_min 0.95955    0.04718   20.336 < 2e-16 ***
High           11.87703    0.93235   12.739 < 2e-16 ***
Medium         5.95285    0.76988    7.732 2.90e-14 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 10.14 on 874 degrees of freedom
Multiple R-squared:  0.7809,    Adjusted R-squared:  0.7789
F-statistic: 389.4 on 8 and 874 DF,  p-value: < 2.2e-16
```

Es importante aclarar que, en este modelo, con un p-valor = 0.1190, la categoría Windy no resulta estadísticamente significativa. Eso indica que no existe evidencia para afirmar que el viento afecte de forma relevante al tiempo de entrega. Esto puede deberse a que existan pocas observaciones en condiciones ventosas o, entre otras alternativas, a que haya poca variabilidad para ese tipo de clima.

El motivo por el cual se tomó a Low como categoría base fue la de evaluar si, manteniendo constantes las demás variables explicativas (condiciones climáticas, distancia al destino y tiempo de preparación), un nivel de tráfico alto duplica el tiempo de retraso respecto a un tráfico intermedio.

Para ello se planteó el siguiente test de hipótesis:

$$H_0 : \beta_{High} = 2 \beta_{Medium} \qquad H_1 : \beta_{High} \neq 2 \beta_{Medium}$$

Obteniendo de esta forma como resultado lo siguiente:

```
Linear hypothesis test:
High - 2 Medium = 0


Model 1: restricted model
Model 2: Delivery_Time_min ~ Foggy + Rainy + Snowy + Windy + Distance_km +
Preparation_Time_min + High + Medium

Res.Df  RSS Df Sum of Sq    F Pr(>F)
1      875 89895
2      874 89895  1  0.041477 4e-04  0.984
```

El resultado del test arrojó un p-valor de 0.984, muy por encima de cualquier nivel de significancia, esto implica que no hay evidencia estadística suficiente para rechazar la hipótesis nula. En otras palabras, no se rechaza la hipótesis de que el tráfico alto duplica el impacto del tráfico medio en el tiempo de entrega, manteniendo constantes el resto de las variables.

G. Generen una variable dummy que tome el valor 1 si la experiencia del rider/driver es nula, y 0 en caso contrario. Obtengan un gráfico de dispersión entre el tiempo de entrega y la distancia, diferenciando si el rider/driver es novato o no lo es. Agreguen las rectas de regresión en cada caso. Luego estimen una regresión donde incluyan la dummy generada junto con una interacción entre la distancia y la dummy. Interpreten.

Luego de la generación de la variable dummy según si el rider es novato o no, se realizó el gráfico de dispersión correspondiente a la relación entre el tiempo de entrega (en minutos) y distancia (en kilómetros) para cada condición. Adicionalmente, se agregaron las rectas de regresión para cada caso.



Tanto para el grupo de novatos como para los no novatos, se observa una relación positiva entre la distancia y el tiempo de entrega lo cual es coherente con la realidad dado que, a mayor distancia que se debe recorrer, se espera que el tiempo para hacerlo sea mayor.

Es posible notar que las pendientes de las rectas son muy similares para ambos grupos, dando cuenta de que no habría una diferencia significativa en cuánto afecta la distancia a recorrer según la experiencia del rider en términos del tiempo que le llevará recorrerla. De todas formas, cabe destacar que el grupo de novatos tiene una demora levemente mayor que los no novatos para distancias más cortas.

Para complementar este análisis, se estimó una regresión donde se incluyó la dummy “Novato” generada junto con la interacción entre la dummy y la distancia a fines de analizar si existen diferencias en el efecto marginal de la distancia sobre el tiempo cuando el rider es novato o no.

```
Residuals:
    Min       1Q   Median       3Q      Max
-36.143  -8.686  -1.253   7.505  73.331

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    26.06148    0.95615   27.257  <2e-16 ***
Novato          6.20452    3.31689    1.871  0.0617 .
Distance_km     2.99236    0.08297   36.067  <2e-16 ***
Novato:Distance_km -0.30260    0.28223   -1.072  0.2839
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 13.39 on 879 degrees of freedom
Multiple R-squared:  0.6157,    Adjusted R-squared:  0.6143
F-statistic: 469.3 on 3 and 879 DF,  p-value: < 2.2e-16
```

El modelo estimado toma una forma del tipo: $Delivery_Time_min = 26.06 + 6.20 * Novato + 2.99 * Distance_km - 0.30 * (Novato * Distance_km)$.

En primer lugar, de la interpretación del intercepto, surge que el tiempo promedio de entrega para un rider no novato es 26.06 minutos cuando la distancia es 0 kilómetros.

El coeficiente de 6.2 asociado a la dummy Novato sugiere que el tiempo de entrega es 6.2 minutos mayor comparado con un rider no novato, cuando la distancia es 0 kilómetros.

Por otro lado, es posible observar que la distancia tiene un efecto positivo y significativo en el tiempo de entrega. Dicho de otra forma, cada kilómetro adicional aumenta el tiempo de entrega en aproximadamente 2.99 minutos para los riders no novatos.

En último lugar, de los resultados que arroja la interacción entre la dummy novato y la distancia, se concluye que la misma no resulta estadísticamente significativa con un p-valor = 0.2839. El coeficiente de -0.3 indica cómo cambia el efecto de la distancia en el tiempo de entrega cuando el rider es novato: como mencionamos anteriormente, para los no novatos, cada kilómetro adicional aumenta el tiempo de entrega en casi 3 minutos. Para los riders novatos, ese aumento es de $2.99 - 0.3 = 2.69$ minutos por cada kilómetro adicional.

Sobre la interacción, es posible concluir que la pendiente de la relación entre distancia y tiempo no difiere significativamente según cuál sea la experiencia del rider.

H. Vuelvan a estimar el modelo del punto (d), pero ahora expresen la variable dependiente en logaritmo. ¿Cómo cambia la interpretación de cada uno de los coeficientes?

En este caso, se realizó una transformación logarítmica sobre la variable dependiente y se modifica la interpretación de los coeficientes.

```
Residuals:
    Min       1Q   Median       3Q      Max
-1.05339 -0.12474  0.00493  0.11572  1.02612

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.9691031   0.0224921  132.006 < 2e-16 ***
Foggy        0.1646482   0.0226474    7.270 7.96e-13 ***
Rainy        0.0949941   0.0177114    5.363 1.05e-07 ***
Snowy        0.1838792   0.0239477    7.678 4.30e-14 ***
Windy        0.0569499   0.0239262    2.380 0.0175 *
Distance_km   0.0580605   0.0011998   48.393 < 2e-16 ***
Preparation_Time_min 0.0198559   0.0009394   21.137 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.202 on 876 degrees of freedom
Multiple R-squared:  0.7684,    Adjusted R-squared:  0.7668
F-statistic: 484.4 on 6 and 876 DF,  p-value: < 2.2e-16
```

En este caso, el intercepto no tiene una interpretación muy útil dado que representa el valor del $\log(\text{Delivery_Time_min})$ cuando todas las variables valen 0.

En contrapartida con eso, es posible observar que todos los coeficientes toman valores positivos, representando que en climas de niebla, lluvia, nieve o viento, el tiempo de entrega aumenta con respecto al clima despejado. Además de positivos, todos los efectos climáticos resultan estadísticamente significativos.

Ahora bien, ese aumento con respecto a la categoría base (Clear), debe ser interpretado en este caso como aumentos porcentuales: en días de niebla, el tiempo de entrega es un 16.46% mayor que en días despejados; en días de lluvia es 9.49% mayor que en días despejados; en días con nieve aumenta un 18.38% el tiempo de entrega en comparación con días despejados y en días ventosos, el aumento es de 5.69% respecto de días despejados.

Por otro lado, por cada kilómetro adicional, el tiempo de entrega aumenta un 5.8% mientras que, por cada minuto adicional en la preparación del pedido, el tiempo de entrega aumenta 1.9%.

En este caso, por el tipo de transformación que se realizó sobre la variable dependiente, no es posible comparar su R^2 con la del modelo original porque no son comparables las varianzas de Y y $\log(Y)$. Como se alteró su varianza, no son comparables sus R^2 .

De todas formas, mirando el R^2 específico para el modelo log-lin, es posible ver que toma el valor de 0.7684, lo cual permite decir que el modelo tiene una adecuada explicación de la variación de los datos. Asimismo, para cualquier valor de significatividad, todas las variables son significativas al 5%.

I. Incorporen al modelo del punto anterior (h) un término cuadrático de la distancia. ¿Cómo interpretan el efecto de la distancia sobre el tiempo de entrega?

Al incorporar en el modelo el término cuadrático de la distancia, el efecto marginal ya no es constante, sino que depende de ella.

```
Residuals:
    Min       1Q   Median       3Q      Max
-0.94580 -0.12689  0.00629  0.10488  1.08775

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   2.8156882   0.0270698  104.016 < 2e-16 ***
Foggy         0.1653680   0.0216164   7.650 5.29e-14 ***
Rainy         0.0983637   0.0169089   5.817 8.39e-09 ***
Snowy         0.1956095   0.0228922   8.545 < 2e-16 ***
Windy         0.0561464   0.0228371   2.459  0.0141 *
Distance_km    0.1008917   0.0047439  21.268 < 2e-16 ***
I(Distance_km^2) -0.0021146   0.0002273  -9.304 < 2e-16 ***
Preparation_Time_min 0.0200342  0.0008968  22.339 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.1928 on 875 degrees of freedom
Multiple R-squared:  0.7893,    Adjusted R-squared:  0.7876
F-statistic: 468.1 on 7 and 875 DF,  p-value: < 2.2e-16
```

Con el término cuadrático incluido en el modelo, es posible decir que, si bien el tiempo de entrega aumenta a medida que la distancia es mayor, este efecto se reduce por el coeficiente cuadrático negativo. Es decir, a medida que aumenta la distancia aumenta también el tiempo de entrega, pero cada vez a una tasa menor. Entonces, el efecto marginal de la distancia resulta decreciente sobre el tiempo de entrega: cada kilómetro adicional, aumenta menos tiempo que el anterior.

Como observación adicional, sería posible encontrar la distancia donde se alcanza el tiempo máximo de entrega (en logaritmos) realizando la derivada de la regresión en función de la distancia e igualando a 0 la expresión resultante para encontrar el punto crítico.

J. Reporten en una única tabla (usando el paquete [stargazer](#)) los resultados de todas las regresiones estimadas hasta el momento. Expliquen en qué casos es válido comparar el R^2 ajustado entre modelos. Justifiquen su respuesta.

Dependent variable:							
	Reg (1)	Reg1 (2)	Delivery Time Reg2 (3)	Reg3 (4)	Reg4 (5)	log(Delivery Time) Reg2.1 (6)	Reg2.2 (7)
Clear	-1.476 (1.539)						
Foggy	5.416*** (1.923)	6.892*** (1.458)	7.657*** (1.241)	7.979*** (1.139)		0.165*** (0.023)	0.165*** (0.022)
Rainy	3.021* (1.694)	4.496*** (1.141)	4.726*** (0.970)	4.724*** (0.890)		0.095*** (0.018)	0.098*** (0.017)
Snowy	8.507*** (1.987)	9.983*** (1.543)	9.555*** (1.312)	9.929*** (1.205)		0.184*** (0.024)	0.196*** (0.023)
Windy		1.476 (1.539)	2.863** (1.311)	1.879 (1.204)		0.057** (0.024)	0.056** (0.023)
Novato					6.205* (3.317)		
Distance_km	2.933*** (0.077)	2.933*** (0.077)	2.965*** (0.066)	2.961*** (0.060)	2.992*** (0.083)	0.058*** (0.001)	0.101*** (0.005)
I(Distance_km2)							-0.002*** (0.0002)
Preparation_Time_min			0.944*** (0.051)	0.960*** (0.047)		0.020*** (0.001)	0.020*** (0.001)
High				11.877*** (0.932)			
Medium				5.953*** (0.770)			
Novato:Distance_km					-0.303 (0.282)		
Constant	25.585*** (1.604)	24.109*** (0.982)	7.483*** (1.232)	2.459** (1.222)	26.061*** (0.956)	2.969*** (0.022)	2.816*** (0.027)
Observations	883	883	883	883	883	883	883
R2	0.638	0.638	0.738	0.781	0.616	0.768	0.789
Adjusted R2	0.636	0.636	0.737	0.779	0.614	0.767	0.788
Residual Std. Error	13.015 (df = 877)	13.015 (df = 877)	11.068 (df = 876)	10.142 (df = 874)	13.394 (df = 879)	0.202 (df = 876)	0.193 (df = 875)
F Statistic	309.082*** (df = 5; 877)	309.082*** (df = 5; 877)	412.253*** (df = 6; 876)	389.396*** (df = 8; 874)	469.343*** (df = 3; 879)	484.412*** (df = 6; 876)	468.132*** (df = 7; 875)
Note: *p<0.1; **p<0.05; ***p<0.01							

En este caso, es válida la comparación del resultado que arroja el R^2 ajustado entre modelos únicamente cuando los modelos tienen la misma variable dependiente y varían los regresores: la comparación del R^2 ajustado se realiza para penalizar por las variables que se van agregando al modelo.

En ese sentido, para los modelos reg a reg4 es correcto y útil comparar sus R^2 ajustados dado que tienen la misma variable dependiente (Delivery_Time_min).

Para los modelos log-lin (reg2.1 y reg2.2) en cambio, no se deben comparar el R^2 con los modelos anteriores dado que la variable dependiente fue modificada de forma logarítmica y, por ende, la escala de la misma difiere de las demás.

El R^2 es una medida que indica en qué proporción la variable y (tiempo de entrega) está siendo explicada por el modelo. Así, el R^2 ajustado ($\bar{R}^2$) permite corregir por grados de libertad y comparar el ajuste entre dos o más modelos que tienen distinta cantidad de predictores sobre una misma variable y. Por eso, en su cálculo, incluye un factor de penalización que depende del tamaño de la muestra y de la cantidad de predictores del modelo.

Como conclusión, es una métrica que permite comparar el poder predictivo de dos o más modelos y el efecto va a depender del poder que tenga el regresor adicional. Si agrego un regresor y $\bar{R}^2$ no cambia o disminuye, ese regresor que agregué no tuvo un aporte representativo. Caso contrario, el aporte relativo de la variable adicional es útil para explicar la variabilidad del tiempo de entrega.

A partir de esta lógica, en el inciso a continuación, se seleccionarán los modelos de mejor y peor ajuste.

K. Elijan, entre los modelos sin logaritmos, el modelo de mejor y peor ajuste. Con ambos modelos predigan el tiempo de delivery para todas las observaciones de la muestra y obtengan los errores de predicción. Reporten los principales estadísticos descriptivos de los errores de predicción de cada modelo, y calculen el RMSE y MAPE. ¿Qué observan?

Al comparar los modelos reg3 y reg4, se observa que la primera presenta un mejor ajuste general que la segunda, lo cual se refleja en la comparación de sus coeficientes de determinación ajustados y la cantidad y relevancia de los regresores incluidos.

En particular, el modelo reg3 alcanza un R^2 ajustado de 0,779, lo cual indica una alta capacidad explicativa del modelo: cerca del 78% de la variabilidad observada en el tiempo de entrega se encuentra explicada por las variables incorporadas. En cambio, la reg4 muestra un R^2 ajustado considerablemente menor, de 0,614 siendo la peor de todas, evidenciando una menor proporción de variabilidad explicada por el modelo y, por tanto, un ajuste mucho más limitado.

Con el objetivo de evaluar la calidad predictiva de los modelos, se analizaron los errores de predicción, definidos como la diferencia entre el tiempo de entrega real y el estimado por cada modelo. A continuación, se presentan los principales estadísticos descriptivos para dichos errores.

```
> summary(error_mejor)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
-20.478 -5.107  -1.219   0.000   3.327  64.365
> summary(error_peor)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
-36.143 -8.686  -1.253   0.000   7.505  73.331
```

Para la reg3, se observa que la media de los errores es 0 indicando que, en promedio, el modelo no tiende a subestimar ni sobreestimar los tiempos de entrega.

Dado que la mediana de los errores arroja un valor de -1,219, indica una ligera tendencia a sobreestimar los tiempos de entrega. Además, el rango intercuartílico se extiende entre -5,107 y 3,327 minutos, lo cual evidencia una variabilidad moderada. Los valores extremos de error oscilan entre -20,478 y 64,365 minutos, sin mostrar outliers excesivos ni comportamientos atípicos graves.

En contraste, la reg4 también presenta una media igual a 0 lo cual indica que el modelo no presenta sesgos en promedio. Con una mediana de -1,253, muy similar a la de reg3, indica también una leve sobreestimación promedio.

Sin embargo, la dispersión es considerablemente mayor: el primer cuartil se sitúa en -8,686 y el tercero en 7,505, lo que da un rango intercuartílico superior al de la reg3. Esto representa mayor variabilidad en las predicciones.

Asimismo, los valores extremos son más amplios, con un mínimo de -36,143 y un máximo de 73,331 minutos, lo que también refleja una mayor inestabilidad en las predicciones.

Por otro lado, la reg3 y la reg4 fueron evaluadas a partir del Error Cuadrático Medio (RMSE) y el Error Porcentual Absoluto Medio (MAPE).

rmse_mejor	10.0899269546447	mape_mejor	10.9848811177074
rmse_peor	13.3638675418492	mape_peor	20.2333035566808

En cuanto al modelo de la reg3, previamente identificado como el más preciso en términos de dispersión de errores, también presenta mejores métricas de ajuste. Su RMSE es de 10,09 minutos, significativamente menor al RMSE de 13,36 minutos observado para la reg4. Esta diferencia implica que, en promedio, las predicciones de la reg3 se desvían del valor real en menor medida, penalizando especialmente los errores más grandes por tratarse de una métrica cuadrática.

Además, el MAPE de la reg3 es de 10,98%, frente al 20,23% de la reg4. Este resultado indica que, en promedio, los errores de predicción del primero representan aproximadamente un 11% del valor real, mientras que en la segunda los errores alcanzan más del 20%. Dado que el MAPE expresa la magnitud del error relativo, reg3 proporciona estimaciones más cercanas y consistentes en términos proporcionales, independientemente del tamaño del tiempo de entrega real.

L. Reshuffling. A partir del modelo de mejor ajuste del punto anterior, queremos realizar un test placebo que nos permita demostrar que el efecto de la distancia sobre el tiempo de delivery no existe cuando no debería existir. ¿Cómo es esto? El objetivo es realizar un experimento basado en los datos observados, en el que se permute muchas veces (i.e. 10.000 veces) en forma aleatoria los valores de la variable de distancia (únicamente) entre órdenes, estimar la regresión para cada permutación y comparar los coeficientes y p-values de la variable de distancia con los observados en la regresión con la muestra original. Implemente dicha prueba, comente los resultados y la intuición detrás de este enfoque.

Con el objetivo de validar la robustez del efecto observado de la distancia sobre el tiempo de entrega, se implementó una prueba de permutación. Lo que se busca es permutar aleatoriamente los valores de la variable Distance_km entre observaciones, de manera que se rompa cualquier posible asociación real entre dicha variable y la variable dependiente (Delivery_Time_min). A partir de esta reordenación, se estimó el mismo modelo de regresión utilizado previamente, repitiendo este procedimiento 10.000 veces. En cada iteración se almacenó el coeficiente asociado a Distance_km.

```
> # Modelo de mejor ajuste:
> reg3 <- lm(Delivery_Time_min ~ Foggy + Rainy + Snowy + Windy + Distance_km +
+           Preparation_Time_min + High + Medium, data = datos_filtrados)
>
> # Se guarda el coeficiente de la distancia del modelo de mejor ajuste
> coef_mejor <- coef(reg3)["Distance_km"]
>
> coef_simulados <- c()
>
> # Se repite el proceso 10000 veces
> set.seed(123)
> for (i in 1:10000) {
+   datos_simul <- datos_filtrados
+   datos_simul$Distance_km <- sample(datos_filtrados$Distance_km)
+   modelo_simulado <- lm(Delivery_Time_min ~ Foggy + Rainy + Snowy + Windy + Distance_km +
+                         Preparation_Time_min + High + Medium, data = datos_simul)
+   coef_simulados[i] <- coef(modelo_simulado)["Distance_km"]
+ }
```

Luego, se calculó un p-valor empírico como la proporción de simulaciones en las que el valor absoluto del coeficiente permutado fue mayor o igual al valor absoluto del coeficiente estimado en el modelo original.

```
> # Se calcula el p-valor empírico: cuántos coeficientes simulados son tan extremos como el real
>
> p_empirico <- mean(abs(coef_simulados) >= abs(coef_mejor))
> print(p_empirico)
[1] 0
```

El resultado fue un p-valor empírico igual a 0, lo que indica que ninguna de las 10.000 permutaciones generó un coeficiente tan extremo como el observado en los datos reales. Este resultado proporciona evidencia contundente de que el efecto estimado de la distancia sobre el tiempo de entrega no es atribuible al azar. En otras palabras, la relación observada en el modelo original refleja un patrón sistemático en los datos, y no un resultado influenciado por la correlación aleatoria.